

1. **kernel 这个东西在 SVM 中真的只是一少部分**，为了面试的话大概了解一下就可以了，面试官也很少有懂的。并不是说大家不爱学习，而是做 kernel 的人根本不关心 SVM 是什么，做 SVM 的人也根本不用关心 kernel 是个什么鬼。

2. **kernel 和 SVM 是两个完全没有关系的概念**。实际上在 SVM 提出以前，人们就提出了再生核希尔伯特空间（reproducing kernel Hilbert space, RKHS）这个概念，并且把它应用在信号处理中。如：在信号检测（signal detection）问题中，对于一条时间序列（time series），我如何知道它是一个随机步行（random walk）的噪音序列呢？还是有一个特定的模式（pattern）在里面呢？在这个情景下，RKHS 理论就给出了一个通过求解似然率（likelihood ratio）的假设检验方案，其中的 kernel 是某个随机过程在两个不同时间点的相关性（correlation）。

另外，核方法可以用在 逻辑斯谛回归（logistic regression）、最小二乘法（least square）、降维（dimension reduction）等多处地方，也不是只和 SVM 这个概念绑定的。

## 在SVM中的应用

简单说几句，公式太难写了（笑）。


我们在用原始数据  $x$  的时候发现数据并不可分，所以就寄希望于一个映射  $\Phi(x)$ ，这个映射把低维空间上的数据映射到高维空间，这样数据集就有可能变得可分了。

但是在考虑优化问题的对偶问题时，需要计算  $\langle x_i, x_j \rangle$ ，请注意，我们已经把所有的  $x$  换成了  $\Phi(x)$ ，所以就变成需要计算  $\langle \Phi(x_i), \Phi(x_j) \rangle$ 。

为了不让计算变得很困难，我们就可以找到一个核函数  $K$ ，满足  $K$  可以生成  $\Phi$  所形成的高维空间，这样  $\langle \Phi(x_i), \Phi(x_j) \rangle$  就可以简单的用  $K(x_i, x_j)$  代替了。而  $K$  往往定义成和  $x$  的内积有关的式子，这样在低维空间中计算内积就很简单。

如：径向基函数里有  $\|x - y\|^2$ ，展开以后其实就含有两个范数项（注意范数就是内积）和一个内积项。

# SVM



$$\begin{cases} w^T x_1 + b = 1 \\ w^T x_2 + b = -1 \end{cases}$$

$$w^T (x_1 - x_2) = 2$$

$$\frac{w^T}{\|w\|} (x_1 - x_2) = \frac{2}{\|w\|} \leftarrow \text{间隔}$$

↑ 投影

$$\max \frac{2}{\|w\|}$$

问题

$$\min \frac{1}{2} \cdot w^T w$$

$$\text{s.t. } y_i (w x_i + b) \geq 1$$

$$\text{目标函数} \quad 1 - y_i (w x_i + b) + \alpha_i^2 = 0$$

$$\text{对偶问题: } \max_{\alpha} W(\alpha)$$

$$\text{其中: } W(\alpha) = \min \left[ \frac{1}{2} w^T w + \sum \alpha_i [1 - y_i (w x_i + b) + \alpha_i^2] \right]$$

$$\text{对于 } L = \frac{1}{2} w^T w + \sum \alpha_i [1 - y_i (w x_i + b) + \alpha_i^2]$$

$$\begin{cases} \frac{\partial L}{\partial w} = w - \sum \alpha_i y_i x_i = 0 \Rightarrow w = \sum \alpha_i y_i x_i \\ \frac{\partial L}{\partial \alpha_i} = 1 - y_i (w x_i + b) + 2\alpha_i = 0 \Rightarrow \alpha_i \geq 0 \\ \frac{\partial L}{\partial b} = \sum \alpha_i (-y_i) = 0 \Rightarrow \sum \alpha_i y_i = 0 \end{cases}$$

$$w^T w = \left( \sum \alpha_i y_i x_i \right)^T \left( \sum \alpha_j y_j x_j \right) = \sum \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$w^T x_i = \sum \alpha_j y_j x_j^T x_i$$

$$W(\alpha) = \frac{1}{2} \sum \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum \alpha_i - \sum \alpha_i y_i \sum \alpha_j y_j x_j^T x_i + \sum \alpha_i \overset{=0}{b} + \sum \alpha_i \overset{=0}{\alpha_i^2}$$

$$= \sum \alpha_i - \frac{1}{2} \sum \alpha_i \alpha_j y_i y_j x_i^T x_j$$

## 核 SVM

现在问题为  $\max_{\alpha} W(\alpha) = \sum \alpha_i - \frac{1}{2} \sum \sum \alpha_i \alpha_j y_i y_j x_i x_j$

$$\text{s.t. } \sum \alpha_i y_i = 0$$

$$\alpha_i \geq 0$$

↓ 核化

$$\max_{\alpha} W(\alpha) = \sum \alpha_i - \frac{1}{2} \sum \sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

SV

• 许多  $\alpha_i^*$  为 0,

支持向量.

$$W = \sum y_i \alpha_i x_i$$

$$y = W^T x + b = \sum y_i \alpha_i x_i^T x + b$$

$$\text{核化: } y = \sum y_i \alpha_i K(x_i, x) + b$$

b

• 在支持向量有

$$W^T x + b = y$$

$$\sum y_i \alpha_i x_i^T x + b = y \Rightarrow b^* = y - \sum y_i \alpha_i x_i^T x$$

# Prediction.

$$y_{new} = \text{sign}(\sum \alpha_i y_i K(x_i, x_{new}) + b)$$

