


## 6. SVM.

logistic regression

$$\text{Cost} = -(y \log h_{\theta}(x) + (1-y) \log (1-h_{\theta}(x)))$$


1. 分类, 可计算概率.



线性小: 两者可互换.  
非线性小: 核函数, 只问 SVM

SVM

$$\text{Cost} = \min_{\theta} C \sum_{i=1}^m [y^{(i)} \text{Cost}_1(\theta^T x^{(i)}) + (1-y^{(i)}) \text{Cost}_2(\theta^T x^{(i)})] + \frac{1}{2} \sum_{i=1}^n \theta_i^2$$



problem & solution

可分问题

$$\text{目标: } \min_{w,b} \frac{1}{2} \|w\|^2$$

$$y_i(w x_i + b) \geq 1$$

对偶问题

$$\begin{cases} \max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{s.t. } \sum_{i=1}^m \alpha_i y_i = 0 \quad \alpha_i \geq 0 \end{cases}$$

SMD 算法

step 1. 选择  $\alpha_i, \alpha_j$ .  $\alpha_i$ : 违背 KKT 最大  
 $\alpha_j$ :  $|E_i - E_j|$  最大  
step 2. 固定其他参数, 对偶式, 求  $\alpha_i, \alpha_j$ .

不可分

核方法

$$K(x_i, x_j) = \langle \phi_i, \phi_j \rangle$$

高维映射内积

低维, 在函数下的相似性.

$$\text{常用} \begin{cases} \text{高斯核: } \exp(-\frac{\|x_i - x_j\|^2}{2\sigma^2}) \\ \text{线性核: } K(x_i, x_j) = x_i^T x_j \end{cases}$$

软间隔

目标函数同硬间隔

$$\begin{cases} 0 \leq \alpha_i \leq C \end{cases} \text{ 不同类.}$$









