

1. **kernel 这个东西在 SVM 中真的只是一少部分**，为了面试的话大概了解一下就可以了，面试官也很少有懂的。并不是说大家不爱学习，而是做 kernel 的人根本不关心 SVM 是什么，做 SVM 的人也根本不用关心 kernel 是个什么鬼。

2. **kernel 和 SVM 是两个完全没有关系的概念**。实际上在 SVM 提出以前，人们就提出了再生核希尔伯特空间 (reproducing kernel Hilbert space, RKHS) 这个概念，并且把它应用在信号处理中。如：在信号检测 (signal detection) 问题中，对于一条时间序列 (time series)，我如何知道它是一个随机步行 (random walk) 的噪音序列呢？还是有一个特定的模式 (pattern) 在里面呢？在这个情景下，RKHS 理论就给出了一个通过求解似然率 (likelihood ratio) 的假设检验方案，其中的 kernel 是某个随机过程在两个不同时间点的相关性 (correlation)。

另外，核方法可以用在 逻辑斯谛回归 (logistic regression)、最小二乘法 (least square)、降维 (dimension reduction) 等多处地方，也不是只和 SVM 这个概念绑定的。

在SVM中的应用

简单说几句，公式太难写了（笑）。


我们在用原始数据 x 的时候发现数据并不可分，所以就寄希望于一个映射 $\Phi(x)$ ，这个映射把低维空间上的数据映射到高维空间，这样数据集就有可能变得可分了。

但是在考虑优化问题的对偶问题时，需要计算 $\langle x_i, x_j \rangle$ ，请注意，我们已经把所有的 x 换成了 $\Phi(x)$ ，所以就变成需要计算 $\langle \Phi(x_i), \Phi(x_j) \rangle$ 。

为了不让计算变得很困难，我们就可以找到一个核函数 K ，满足 K 可以生成 Φ 所形成的高维空间，这样 $\langle \Phi(x_i), \Phi(x_j) \rangle$ 就可以简单的用 $K(x_i, x_j)$ 代替了。而 K 往往定义成和 x 的内积有关的式子，这样在低维空间中计算内积就很简单。

如：径向基函数里有 $\|x - y\|^2$ ，展开以后其实就含有两个范数项（注意范数就是内积）和一个内积项。

SVM



$$\begin{cases} w^T x_1 + b = 1 \\ w^T x_2 + b = -1 \end{cases}$$

$$w^T (x_1 - x_2) = 2$$

$$\frac{w^T}{\|w\|} (x_1 - x_2) = \frac{2}{\|w\|} \leftarrow \text{间隔}$$

↑ 投影

$$\max \frac{2}{\|w\|}$$

问题

$$\min \frac{1}{2} \cdot w^T w$$

$$\text{s.t. } y_i (w x_i + b) \geq 1$$

$$\text{转化为等式 } 1 - y_i (w x_i + b) + \alpha_i^2 = 0$$

$$\text{对偶问题: } \max_{\alpha} W(\alpha)$$

$$\text{其中: } W(\alpha) = \min \left(\frac{1}{2} w^T w + \sum \alpha_i [1 - y_i (w x_i + b) + \alpha_i^2] \right)$$

$$\text{对于 } L = \frac{1}{2} w^T w + \sum \alpha_i [1 - y_i (w x_i + b) + \alpha_i^2]$$

$$\begin{cases} \frac{\partial L}{\partial w} = w + \sum \alpha_i y_i x_i = 0 \Rightarrow w = -\sum \alpha_i y_i x_i \\ \frac{\partial L}{\partial \alpha_i} = 1 - y_i (w x_i + b) + 2\alpha_i = 0 \Rightarrow d_i \alpha_i = 0 \\ \frac{\partial L}{\partial b} = \sum \alpha_i (-y_i) = 0 \Rightarrow \sum \alpha_i y_i = 0 \end{cases}$$

$$w^T w = \left(\sum \alpha_i y_i x_i \right)^T \left(\sum \alpha_j y_j x_j \right) = \sum \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$w^T x_i = \sum \alpha_j y_j x_j^T x_i$$

$$W(\alpha) = \frac{1}{2} \sum \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum \alpha_i - \sum \alpha_i y_i \sum \alpha_j y_j x_j^T x_i + \sum \alpha_i b + \sum \alpha_i^2$$

$$= \sum \alpha_i - \frac{1}{2} \sum \alpha_i \alpha_j y_i y_j x_i^T x_j$$

核 SVM

现在问题为 $\max_{\alpha} W(\alpha) = \sum \alpha_i - \frac{1}{2} \sum \sum \alpha_i \alpha_j y_i y_j x_i x_j$

$$\text{s.t. } \sum \alpha_i y_i = 0$$

$$\alpha_i \geq 0$$

↓ 核化

$$\max_{\alpha} W(\alpha) = \sum \alpha_i - \frac{1}{2} \sum \sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

SV

• 许多 α_i^* 为 0,

支持向量:

$$W = \sum y_i \alpha_i x_i$$

$$y = W^T x + b = \sum y_i \alpha_i x_i^T x + b$$

$$\text{核化: } y = \sum y_i \alpha_i K(x_i, x) + b$$

b

• 在支持向量有

$$W^T x + b = y$$

$$\sum y_i \alpha_i x_i^T x + b = y \Rightarrow b^* = y - \sum y_i \alpha_i x_i^T x$$

Prediction.

$$y_{new} = \text{sign}(\sum \alpha_i y_i K(x_i, x_{new}) + b)$$

